

# Problem najmniejszego pokrycia wierzchołków w grafie- algorytm ewolucyjny

## Wersja języka

- Python - 3.9.7

## Używane biblioteki

- Random
- Timeit

## Dane wejściowe

Wszystkie testy odbywały się na grafie pełnym z którego losowo usunąłem 50% krawędzi. Graf ma 25 wierzchołków, czyli posiada  $25 \cdot 24 / 2 = 300$  krawędzi. Po usunięciu  $300 - 150 = 150$  krawędzi. Graf reprezentowany jest jako lista par wierzchołków które się ze sobą łączą. Osobnik reprezentowany jest przez 25 elementowa listę składającą się z 0 i 1 (0 oznacza zgaszoną latarnie, 1 oznacza zapaloną latarnie) reprezentujących latarnie znajdującą się na wierzchołku o numerze indeksu bitu. Osobnicy w bazowej populacji są tworzeni losowo.

## Selekcja turniejowa

W trakcie każdej iteracji programu tworzonych jest tyle turniejów, ile obiektów jest w generacji. Do turnieju losowo wybierane jest 2 osobników bez zwracania. Z każdego turnieju do nowej populacji przechodzi ten osobnik, który osiągnął mniejszy wynik w trakcie oceny. Ocena zachodzi według wzoru  $ocena = x + 1000 * y$ , gdzie x oznacza ilość zapalonych latarni a y ilość nierozświetlonych dróg. Funkcja została określona w taki sposób, aby algorytmowi nie opłacało się pozostawiać nierozświetlonych dróg. Dużym plusem powyższej funkcji heurystycznej jest łatwe określenie jak zachował się nasz program. W wyniku liczba tysięcy oznacza ilość nierozświetlonych dróg a liczba mniejsza niż tysiąc oznacza ilość zapalonych latarni.

## Mutacja

W trakcie fazy mutacji każda jednostka ma szansę 100% na zmutowanie. Jest ona taka, aby jednostka już wcześniej oceniona i porównana z najlepszą nie marnowała miejsca. Dzięki temu algorytm zamiast kilkakrotnie sprawdzać to samo rozwiązanie rusza się w przestrzeni rozwiązań. Każdy bit jednostki ma 5% na zajście mutacji co daje każdorazową zmianę ok. 1 bitu. Jakby szansa na mutację bitu była mniejsza, wiązałoby się to z kilkakrotnym sprawdzaniem tego samego rozwiązania co spowolniłoby działanie programu. Gdyby szansa mutacji była większa, algorytm tworzyłby losowo nowe obiekty które byłyby mało podobne do rodzica.

## Działanie programu

W tabeli odpowiednio średnie oceny wyników \ średni czas funkcji

Ilość iteracji \ Wielkość populacji	100	1000	2000	5000
5	8219 0,07	22616 0,70	8419 1,40	11917 3,47
25	4620 0,34	2221 3,34	3219 6,67	1221 16,65
100	5019 1,35	3220 13,28	2620 26,46	2220 66,57
250	4219 3,57	3020 33,10	2325 68,34	1221 163,89

## Wnioski

Algorytm radzi sobie dużo lepiej dla większej ilości iteracji. Znacząco zwiększa to szanse na znalezienie minimum globalnego. Przy małej ilości iteracji a nawet bardzo dużej populacji algorytm zatrzymywał się na dostatecznie dobrym wyniku i miał problemy ze znalezieniem lepszego rozwiązania. Duża liczba iteracji znacząco spowalnia program co jest nie wprost proporcjonalne z jakością znalezionego wyniku.